

Tarea S6 - AJUSTES AL PROTOTIPO



Grupo: Patricio Bayas Meza, José Puebla Paladines, Marco Zurita Rojas

Fecha: 19 de julio de 2026

Contexto. En S6 el baseline (TF-IDF + Regresión Logística a nivel de nota) no superó el azar sobre MEDEC (ROC-AUC = 0.504) porque la oración errónea representa solo ~9 % del texto y el 95,6 % del vocabulario se solapa entre clases. Este informe implementa y evalúa estadísticamente un ajuste que ataca esa causa raíz, y deja preparada la comparación tripartita (TF-IDF vs. LLM zero-shot vs. LLM + RAG) recomendada.

1. Ajustes del prototipo

1.1. ¿Qué ajustes se realizaron?

- **Reformulación de la tarea (preprocesamiento + enfoque de modelado).** Se pasó de clasificar la nota completa a clasificar cada oración: “¿es ESTA oración la inconsistente?”, aprovechando el campo Error Sentence ID de MEDEC. Cada nota se explota en sus oraciones numeradas (27.216 oraciones de entrenamiento; prevalencia de la clase positiva 4,5 %).
- **Ingeniería de características.** TF-IDF (n-gramas) combinado, mediante FeatureUnion, con cuatro rasgos numéricos por oración —longitud, nº de palabras, nº de dígitos y presencia de negación— estandarizados, que capturan señales que la bolsa de palabras no modela bien.
- **Ajuste de hiperparámetros.** Búsqueda en malla (ngram_range $\in \{1, (1-2)\}$; C $\in \{0,5, 1, 2\}$) optimizando ROC-AUC con validación cruzada estratificada de 5 pliegues. Mejor configuración: n-gramas unigrama, C = 1,0.
- **Manejo del desbalance.** class_weight = balanced (solo una oración positiva por nota).

1.2. ¿Por qué eran necesarios?

El diagnóstico de S6 demostró que el fracaso no era de ajuste sino representacional: a nivel de nota no hay señal léxica. Trabajar a nivel de oración eleva la relación señal-ruido (la señal deja de estar diluida en 9 % del texto) y, además, habilita una capacidad de negocio que el baseline no tenía: localizar la oración problemática dentro de la historia.

1.3. ¿Qué se esperaba mejorar?

Recuperar poder discriminante (ROC-AUC muy por encima de 0,5) a nivel de oración y obtener una localización útil del error, que es lo que un médico revisor necesita: no un “hay algo mal en esta nota”, sino “revise esta frase”.

2. Reporte de análisis estadístico

2.1. Esquema de evaluación y datos

Se usan las particiones oficiales de MEDEC (train 2.189 / val 574 / test 597 notas), sin re-particionar, para evitar fuga de información y garantizar comparabilidad con S6. La selección de hiperparámetros se hace por validación cruzada estratificada de 5 pliegues sobre el entrenamiento; el conjunto de prueba se toca una sola vez. La estratificación es apropiada por el fuerte desbalance (4,5 % de oraciones positivas): mantiene la proporción de clases en cada pliegue y evita métricas frágiles por folds vacíos de positivos. Supuesto clave: las oraciones de una misma nota no se separan entre entrenamiento y prueba (la partición es por nota), lo que evita fuga por contexto compartido.

2.2. Comparación baseline vs. modelo ajustado

Métrica (test MEDEC)	Baseline (nota)	Ajustado (oración)	Lectura
ROC-AUC	0.504	0.948	De azar a fuerte discriminación
F1	0.674*	0.497	*F1 del baseline era espurio (marcaba casi todo)
Recall	0.945*	0.817	Ahora con AUC real que lo respalda
Precision	0.523	0.357	Baja por desbalance extremo (mejorable con umbral)
Localización top-1	n/d	0.846	Acierta la oración errónea en 263/311 notas

Interpretación: reformular la tarea eleva el ROC-AUC de 0,504 a 0,948 y, sobre todo, permite localizar la oración errónea en el 84,6 % de las notas con error. La precisión baja es consecuencia del desbalance (4,5

% positivos) y se gestiona con el umbral de decisión según la carga de revisión aceptable; no invalida el salto de AUC.




Figura 1. (a) el salto de ROC-AUC al pasar a nivel de oración, con IC95 % por bootstrap; (b) estabilidad entre folds; (c) localización top-1 de la oración errónea.

2.3. Variabilidad, incertidumbre y estabilidad

- **Validación cruzada (5 folds):** ROC-AUC = 0,951, 0,968, 0,966, 0,971, 0,968 → media 0,965, desviación 0,007. La baja dispersión indica que el modelo es muy estable: su desempeño no depende de un reparto afortunado de los datos.
- **Intervalos de confianza (bootstrap, 1000 remuestreos) en test:** ROC-AUC 0,948 (IC95 % 0,940-0,958). El intervalo es estrecho y está muy lejos de 0,5, por lo que la conclusión es robusta y no un artefacto del muestreo.
- **Conexión con la confianza en la decisión:** estabilidad alta + IC estrecho + partición sin fuga → podemos afirmar con confianza que el enfoque a nivel de oración es una mejora real, no ruido.

2.4. Prueba de McNemar (a nivel de nota) y un hallazgo importante

Al reagregar las predicciones de oración a nivel de nota (marcar la nota si alguna oración supera el umbral), el modelo ajustado NO mejora la clasificación binaria por nota (AUC 0,46) y la prueba de McNemar frente al baseline da $p = 0,53$: **no hay diferencia significativa a nivel de nota**. Esto es coherente y esperable: MEDEC está diseñado de modo que casi toda nota contiene una oración candidata a error, por lo que “¿la nota tiene error?” es intrínsecamente poco separable. El valor del ajuste no está en la clasificación por nota, sino en la **localización** de la oración, que es la tarea útil para CITIMED.

3. Consolidación del repositorio

El repositorio baseline/ se actualizó con el prototipo ajustado y su documentación. Todo es reproducible con SEED = 42 y las particiones oficiales de MEDEC.

Componente	Descripción
modelo_ajustado.py	Código final del prototipo ajustado (nivel oración, FeatureUnion, GridSearchCV, bootstrap, McNemar, localización).
salidas_ajuste/metricas_ajuste.json	Métricas, folds de CV, IC95 %, McNemar y localización.
salidas_ajuste/figura_ajuste.png	Figura 1 del informe.
README.md	Descripción del proyecto, instrucciones de ejecución, dependencias y versiones.
BITACORA.md	Registro de cambios fechado (S5 → S6 → S7).
requirements.txt	Versiones fijadas: scikit-learn 1.8.0, pandas 3.0.2, numpy 2.4.4, scipy, joblib, matplotlib.

Control de versiones: el proyecto se versiona con Git; cada experimento queda asociado a un commit y a su archivo de métricas JSON. Reproducción: `pip install -r requirements.txt`, luego `git clone` del repo de MEDEC y `python modelo_ajustado.py`.

4. Síntesis reflexiva

4.1. Decisiones técnicas más relevantes

- **Reformular la unidad de análisis (nota → oración):** la decisión de mayor impacto; convirtió un problema “sin señal” (AUC 0,50) en uno resoluble (AUC 0,95) y con localización del error.

- **Evaluar con particiones oficiales y CV estratificada:** asegura comparabilidad con S6 y evita conclusiones frágiles.
- **Reportar AUC + IC + McNemar, no solo F1:** la métrica correcta evita repetir el autoengaño del F1 del baseline.

4.2. Riesgos técnicos y mitigaciones

- **Fuga de datos (leakage).** Riesgo: oraciones de una misma nota en train y test. Mitigación: partición por nota y uso de los splits oficiales.
- **Sobreajuste.** Riesgo: modelo memorizando el train. Mitigación: CV 5-fold + IC bootstrap; la baja varianza entre folds confirma que no lo hay.
- **Falsa confianza por datos sintéticos.** Riesgo ya materializado en S6. Mitigación: los sintéticos quedan solo como prueba de humo; la evaluación es siempre sobre MEDEC real.
- **Datos no representativos / sesgo.** MEDEC es en inglés y de EE. UU.; CITIMED es en español. Mitigación planificada: transferir con embeddings multilingües, auditar por subgrupos y validar sobre el corpus anonimizado de CITIMED.
- **Comparación injusta.** Riesgo: comparar modelos con datos o protocolos distintos. Mitigación: baseline y ajustado se evalúan sobre las mismas notas de test, con McNemar en muestras pareadas.

4.3. Criterio de éxito

Superar la localización top-1 de 0,846 y el ROC-AUC de 0,948 del modelo ajustado, sin degradar el recall en errores críticos de medicación y diagnóstico.