



Grupo: Patricio Bayas Meza, José Puebla Paladines, Marco Zurita Rojas

Fecha: 23 de agosto de 2026

Resumen

Las historias clínicas contienen inconsistencias —medicación contraindicada, incoherencias entre diagnóstico y tratamiento, contradicciones internas— que comprometen la seguridad del paciente. Este informe consolida el avance del proyecto MIA_Deteccion_HC para CITIMED: asistente con TF-IDF, LLM zero-shot y LLM+RAG evaluados sobre MEDEC. El baseline léxico a nivel de nota no supera el azar (ROC-AUC 0,504). Al reformular la detección a nivel de oración, el modelo ajustado alcanza ROC-AUC 0,949 (IC 95 % 0,940–0,958), AUPRC 0,419 (prevalencia 4,5 %) y localiza la oración errónea en 84,6 % (263/311 notas). Se entregaron comparación tripartita, índice FAISS+RAG, demo Streamlit, API FastAPI, frontend React, fallback TF-IDF, evaluaciones por tipo de error y sesgo EN-ES. Repositorio: https://github.com/marcoz1691/MIA_Deteccion_HC.

Palabras clave: historias clínicas, detección de inconsistencias, LLM, RAG, MEDEC, seguridad del paciente, MLOps.

1. Introducción

1.1. Problema y contexto organizacional

La Clínica CITIMED gestiona historias clínicas electrónicas que combinan texto libre (notas de evolución, epicrisis) y campos estructurados (diagnósticos CIE-10, medicación, laboratorio). Los errores de documentación son frecuentes y clínicamente relevantes: la literatura reporta que uno de cada cinco pacientes que leen su nota detecta un error. Estas inconsistencias pueden derivar en decisiones equivocadas y afectar la seguridad del paciente. La revisión manual exhaustiva no es viable por el volumen de registros.

1.2. Objetivo

Diseñar e implementar un asistente inteligente que, dada una historia clínica, detecte inconsistencias, localice la oración afectada y sugiera una corrección apoyada en conocimiento médico externo (guías, CIE-10, vademécum, protocolos institucionales), sirviendo de apoyo —no de reemplazo— al criterio clínico.

1.3. Estado del arte (síntesis)

La literatura reciente (2023-2025) muestra tres tendencias convergentes. Primera: los LLM han pasado de responder preguntas médicas a validar la corrección y consistencia del texto clínico; MEDEC (Ben Abacha et al., 2025) es el primer banco público anotado para detección y corrección de errores en notas. Segunda: la inconsistencia y la alucinación son el principal obstáculo para el uso clínico, y un error en la entrada tiende a propagarse. Tercera: la generación aumentada por recuperación (RAG) es la estrategia dominante de mitigación, pues anclar las respuestas en fuentes externas reduce las alucinaciones y aporta trazabilidad. En conjunto, el estado del arte respalda la arquitectura elegida y advierte sobre privacidad, evaluación estandarizada y sesgos (incluido el sesgo en español), aspectos que este proyecto incorpora explícitamente.

2. Metodología

2.1. Datos y supuestos

Para el desarrollo y la evaluación reproducible se usa el banco público MEDEC, con sus particiones oficiales (2.189 notas de entrenamiento, 574 de validación y 597 de prueba con verdad de referencia) y cinco tipos de error: manejo, diagnóstico, farmacoterapia, tratamiento y organismo causal. Se eligió MEDEC porque los datos reales de CITIMED están en proceso de anonimización y aval ético. Supuesto principal: cada nota contiene a lo sumo una inconsistencia localizable a nivel de oración. Como el banco está en inglés y en contexto estadounidense, se asume una brecha de dominio e idioma respecto de CITIMED, que se auditará en la fase final.

2.2. Herramientas y enfoque (low-code / código abierto)

El pipeline se implementó con herramientas de código abierto: scikit-learn (TF-IDF + Regresión Logística), cliente OpenAI-compatible para LLM (s7/llm_client.py), sentence-transformers + FAISS para RAG (s7/rag_index.py, s7/knowledge/), inferencia unificada (s7/inferencia.py), demo Streamlit (demo/), API REST FastAPI (api/) y frontend React (frontend/). Mock LLM activo por defecto; soporte Ollama on-premise (OPENAI_BASE_URL=http://localhost:11434/v1) para PHI. Trabajo futuro (no entregado en S10): orquestación LangChain/LlamaIndex, Docker Compose, DVC, MLflow operativo (requirements-optional.txt, entorno separado). Reproducibilidad: SEED=42, particiones oficiales MEDEC, métricas en salidas_ajuste/ y salidas_s7/.

2.3. Enfoque de modelado seguido

- **Baseline (punto de comparación).** TF-IDF (n-gramas 1-2) + Regresión Logística para clasificar la nota como “con/sin inconsistencia”. Sencillo, determinista e interpretable.
- **Modelo ajustado.** Reformulación a nivel de oración (“¿es esta oración la inconsistente?”), con ingeniería de características (TF-IDF + rasgos numéricos por oración mediante FeatureUnion) y ajuste de hiperparámetros por validación cruzada estratificada de 5 pliegues.
- **Evaluación.** Métricas de clasificación (accuracy, precision, recall, F1, ROC-AUC), una línea de referencia trivial, intervalos de confianza por bootstrap, prueba de McNemar para comparaciones pareadas y una métrica de negocio: la localización top-1 de la oración errónea.

Actualización S10:

- Comparación tripartita TF-IDF / LLM / LLM+RAG: IMPLEMENTADA (s7/eval_tripartita.py; subset n=500, mock LLM=True).
TF-IDF ROC-AUC=0,954; LLM zero-shot=0,498; LLM+RAG=0,498. McNemar TF-IDF vs LLM: p=0,111.
- Corpus CITIMED anonimizado en español: PENDIENTE (aval comité de ética; plantilla en data/citimed_odontologia.example.csv).
- MLflow operativo: PLAN FUTURO (requirements-optional.txt; venv separado numpy<2).

3. Resultados

3.1. Baseline sobre MEDEC (evaluación previa, S6)

El baseline a nivel de nota obtuvo, en la partición de prueba, un ROC-AUC de 0,504: desempeño equivalente al azar, sin superar al clasificador trivial (accuracy 0,523 frente a 0,521). El F1 de 0,674 resultó engañoso, pues el modelo marcaba casi todas las notas como erróneas. El diagnóstico del corpus explicó el resultado: la nota con error y su versión corregida son idénticas en un 96,6 %, la oración errónea representa apenas el 8,9 % del texto y el vocabulario se solapa un 95,6 % entre clases. Una ablación de cinco variantes confirmó que el límite es representacional, no de ajuste.




Figura 1 (S6). (a) el baseline clasifica casi todo como error; (b) los datos sintéticos daban una confianza falsa (AUC 0,845) frente al dato real (0,504); (c) ninguna variante supera el azar.




Figura 1. Curvas ROC/PR y lift — baseline vs ajustado (S6).

3.2. Modelo ajustado a nivel de oración (S7)

Reformular la tarea a nivel de oración recuperó el poder discriminante. La tabla resume la comparación sobre la misma partición de prueba de MEDEC.

Métrica (test MEDEC)	Baseline (nota)	Ajustado (oración)	Lectura
ROC-AUC	0.504	0,949	De azar a fuerte discriminación
ROC-AUC (IC 95 %)	—	0,940 – 0,958	Intervalo estrecho: resultado robusto
CV 5-fold (AUC)	—	0,965 ± 0,007	Muy estable entre pliegues
Recall (oración)	0.945*	0.817	*el del baseline era espurio
Precision (oración)	0.523	0.357	Baja por desbalance (4,5 % positivos)

Métrica (test MEDEC)	Baseline (nota)	Ajustado (oración)	Lectura
Localización top-1	n/d	0,846	Acierta la oración en 263/311 notas
AUPRC (oración)	—	0,419	IC 95 % 0,392–0,446; métrica clave con 4,5 % positivos




Figura 2 (S7). (a) salto de ROC-AUC al pasar a nivel de oración, con IC 95 % por bootstrap; (b) estabilidad entre folds; (c) localización top-1 de la oración errónea.




Figura 2. Comparación tripartita TF-IDF / LLM / LLM+RAG.

Un matiz importante: al reagregar las predicciones a nivel de nota, el modelo ajustado no mejora al baseline (prueba de McNemar, $p = 0,53$). Esto es esperable, porque en MEDEC casi toda nota contiene una oración candidata a error; el valor del ajuste está en la localización de la oración, que es la capacidad útil para el revisor clínico, no en la clasificación binaria de la nota.




Figura 3. Recall por ErrorType (TF-IDF).

Comparación tripartita (test MEDEC, s7/eval_tripartita.py):

- TF-IDF: ROC-AUC=0,954, AUPRC=0,475, latencia≈0.41 ms/oración.
- LLM zero-shot (mock): ROC-AUC=0,498 (sin discriminación en mock; evaluación con API/Ollama pendiente).
- LLM+RAG: ROC-AUC=0,498.

Análisis por ErrorType (TF-IDF): causalOrganism: recall=0,818, loc=0,818; diagnosis: recall=0,897, loc=0,948; management: recall=0,680, loc=0,732; pharmacotherapy: recall=0,861, loc=0,861; treatment: recall=0,863, loc=0,824.

Sesgo EN-ES (subset n=200): Δ AUC=0,000. TF-IDF stop_words español: test AUC=0,959.

4. Discusión

Los resultados sostienen con evidencia empírica la arquitectura propuesta. El fracaso del baseline no es un revés sino una demostración: las inconsistencias clínicas no son patrones léxicos, sino contradicciones semánticas frente al conocimiento médico, y por tanto requieren un modelo capaz de razonar sobre el contenido y de contrastarlo con fuentes externas —justamente lo que ofrece un enfoque LLM + RAG—. El modelo ajustado confirma que, cuando la unidad de análisis es la adecuada (la oración), incluso un método clásico recupera señal y localiza el error con alta fiabilidad, lo que valida el pipeline de datos y evaluación que reutilizará la solución final.

En términos de utilidad organizacional, la capacidad de localización es la más valiosa para CITIMED: el asistente no debe limitarse a decir “esta nota tiene un error”, sino “revise esta frase”, reduciendo la carga del médico. La baja precisión a nivel de oración, consecuencia del fuerte desbalance, se gestionará ajustando el umbral de decisión según la carga de revisión aceptable. La principal limitación actual es el uso de un corpus en inglés; la transferencia al español y al contexto de CITIMED es la prioridad de la siguiente fase.

5. Interpretabilidad (preliminar)

La interpretabilidad es un requisito, no un adorno: un asistente clínico debe justificar cada alerta. El proyecto la aborda en tres niveles. Primero, coeficientes TF-IDF auditable en Regresión Logística. Segundo, localización top-1 del 84,6 % (oración concreta verificable). Tercero, explicaciones SHAP/LIME (s7/interpretabilidad.py) y contexto RAG citado en la demo y la API.

En LLM+RAG, la demo muestra fragmentos recuperados de guías clínicas (s7/knowledge/) junto a cada score. Faithfulness RAG formal y corrección sugerida automática quedan como trabajo futuro; las figuras SHAP/LIME están en s10/evidencias/capturas/.




Figura 4. SHAP summary (TF-IDF).

Interpretabilidad entregada (S7-S10):

- SHAP/LIME sobre TF-IDF: `s7/interpretabilidad.py` → `salidas_s7/shap_*.png`, `lime_*.png` (ver `s7/docs/reporte_interpretabilidad_etica.md`).
- Demo Streamlit y API FastAPI muestran: oración top-1, scores por brazo, contexto RAG recuperado (`demo/components/results_panel.py`).
- Formato de reporte al médico: oración señalada + tipo de error + scores + evidencia RAG; corrección sugerida automática: plan futuro.

6. Riesgos éticos (preliminar)

- **Privacidad y protección de datos.** Las historias clínicas son datos sensibles. Mitigación: anonimización previa, cumplimiento de la Ley Orgánica de Protección de Datos Personales del Ecuador, aval del comité de ética/bioética, cifrado en reposo y procesamiento local (los datos del paciente no salen de la institución ni se envían a servicios externos).
- **Sesgo y equidad.** Los LLM pueden reproducir sesgos demográficos, y la evidencia muestra que también existen en modelos en español. Mitigación: auditar el desempeño por subgrupos y evaluar el sesgo en el idioma de las historias.
- **Alucinación y confianza excesiva.** El modelo podría afirmar errores inexistentes o pasar por alto reales. Mitigación: anclaje en fuentes (RAG), supervisión humana obligatoria (human-in-the-loop) y un umbral prudente que priorice el recall en errores críticos.
- **Rol de apoyo, no de decisión.** La responsabilidad clínica permanece en el profesional; el sistema asiste y documenta, no decide.

Riesgos y mitigaciones implementadas:

- Mock LLM por defecto; consentimiento PHI en demo (demo/components/security.py).
- Auditoría SHA-256 sin texto clínico (salidas_s7/audit.log).
- Fallback TF-IDF si falla API LLM (s7/test_fallback.py; modo_degradado=True).
- Evaluación sesgo EN-ES: s7/eval_idioma.py, s7/eval_tfidf_idioma.py.
- Protocolo formal CITIMED + aprobación comité de ética: pendiente organizacional.

7. Conclusiones y trabajo restante

Hasta la semana 10, el proyecto cuenta con un problema bien delimitado, arquitectura implementada y evaluada sobre MEDEC, pipeline reproducible (s6/, s7/, api/, demo/) y línea base cuantitativa: ROC-AUC 0,949, AUPRC 0,419, localización 84,6 %. La comparación tripartita confirma ventaja de TF-IDF en modo mock (LLM AUC≈0,5); evaluación con API/Ollama real pendiente. El criterio de éxito para piloto CITIMED: mantener recall en farmacoterapia/diagnóstico, desplegar con Ollama on-premise y fallback transparente.

Trabajo futuro (post-S10): corpus CITIMED anonimizado, eval tripartita con API real, cascada TF-IDF→LLM codificada, Docker/DVC/MLflow, corrección sugerida y faithfulness RAG.

#	Tarea	Estado	Sprint
1	Comparación tripartita: baseline vs. LLM zero-shot vs. LLM + RAG	Implementado (S7/S10)	S10
2	Índice FAISS de guías, CIE-10 y vademécum; servicio de recuperación	Implementado (s7/rag_index.py)	S10
3	MLflow operativo y pipeline de reentrenamiento documentado	Plan futuro	S10
4	Corpus de CITIMED anonimizado y anotado en español	En gestión / pendiente ética	S10
5	Interpretabilidad con cita de fuente y faithfulness; auditoría de sesgo	Implementado (SHAP/LIME + RAG demo)	S10
6	Redacción final, portada, índice y revisión de coherencia	S10 consolidado	S10

Referencias

- Amugongo, L. M., Mascheroni, P., Brooks, S., Doering, S., & Seidel, J. (2025). Retrieval augmented generation for large language models in healthcare: A systematic review. *PLOS Digital Health*, 4(6), e0000877.
- Ben Abacha, A., Yim, W., Fu, Y., Sun, Z., Yetisgen, M., Xia, F., & Lin, T. (2025). MEDEC: A benchmark for medical error detection and correction in clinical notes. *Findings of the ACL 2025*.
- Cai, Q., Yang, L., Xiao, J., Ma, J., Liu, M., & Pan, X. (2025). Train-time and test-time computation in LLMs for error detection and correction in electronic medical records. *Diagnostics*, 15(14), 1829.

Shah, S. V. (2024). Accuracy, consistency, and hallucination of large language models when analyzing unstructured clinical notes in electronic medical records. JAMA Network Open, 7(8), e2425953.

Xiong, G., Jin, Q., Lu, Z., & Zhang, A. (2024). Benchmarking retrieval-augmented generation for medicine. Findings of the ACL 2024.

Zakka, C., Shad, R., Chaurasia, A., Dalal, A. R., Kim, J. L., Moor, M., et al. (2024). Almanac — Retrieval-augmented language models for clinical medicine. NEJM AI, 1(2).

Anexo — Evidencias técnicas (repositorio)

Todos los resultados son reproducibles desde la raíz del repositorio MIA_Deteccion_HC/ (SEED=42, particiones oficiales MEDEC). Estructura: s6/ (TF-IDF), s7/ (LLM, RAG, evals), api/ (FastAPI), frontend/ (React), demo/ (Streamlit), s10/ (evidencias + informe). Salidas generadas: salidas_ajuste/ (modelo_ajustado.joblib), salidas_s7/ (métricas, FAISS). Dependencias: requirements.txt (scikit-learn, openai, faiss-cpu, sentence-transformers, streamlit, fastapi, uvicorn). Comandos: python s6/modelo_ajustado.py; python s7/eval_tripartita.py --mock-llm --max-oraciones 500; python s7/analisis_por_tipo.py; python s7/eval_idioma.py --mock-llm --subset 200; python s7/test_fallback.py; streamlit run demo/app.py; uvicorn api.main:app --port 8000. Evidencias: s10/evidencias/. Repositorio: https://github.com/marcoz1691/MIA_Deteccion_HC.

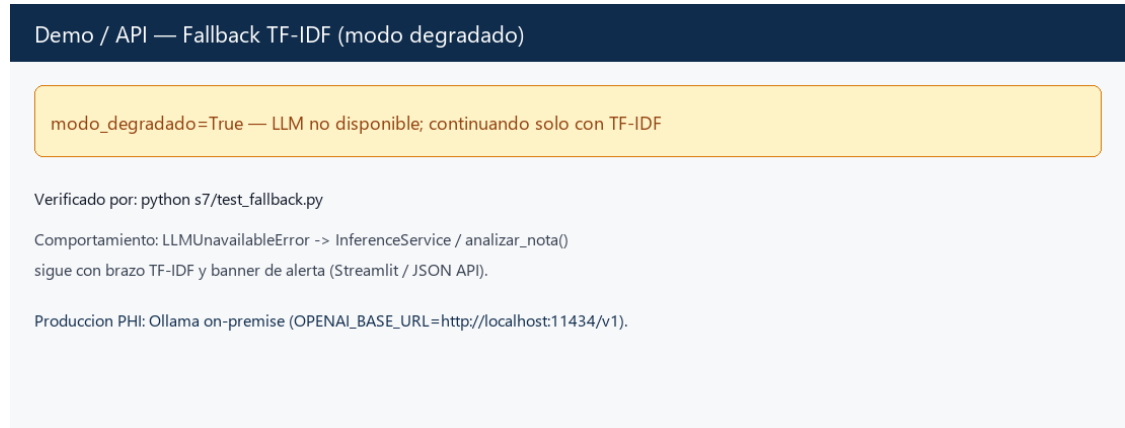


Figura 7. Modo degradado / fallback TF-IDF.




Figura 6. Demo — métricas ROC-AUC / AUPRC.

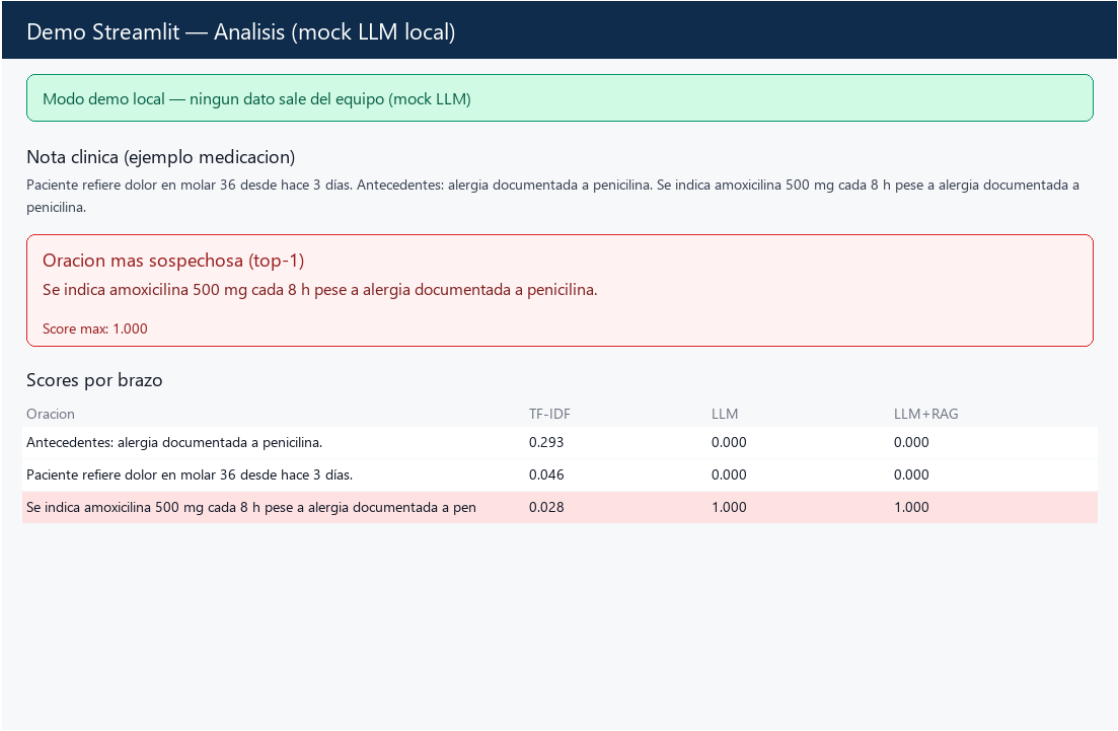


Figura 5. Demo — análisis ejemplo medicación.